

<Machine Learning HW #1>

21300008 강민수

1.5. Using the definition (1.38) show that $\text{var}[f(x)]$ satisfies (1.39).

Definition (1.38.): $\text{var}[f] = \mathbb{E}[(f(x) - \mathbb{E}[f(x)])^2]$

Definition (1.39.): $\text{var}[f] = \mathbb{E}[f(x)^2] - \mathbb{E}[f(x)]^2$

Proof)

x 가 discrete random variable인지, continuous random variable인지에 따라, expectation의 정의가 달라지고, 그 증명 과정이 달라진다. 따라서 x 가 discrete인 경우와 continuous인 경우로 나누어 증명을 수행하였다.

(1) x 가 discrete일 때

x 가 discrete random variable인 경우 any real valued probability mass function $f(x)$ 의 기대값, $\mathbb{E}[f(x)]$ 는 $\sum_x f(x)p(x)$ 로 나타낼 수 있다. (이는 증명 대상이 아니므로 생략한다.) 이를 μ 라 하자. 그렇다면 definition 1.38은 아래와 같이 전개할 수 있다.

$$\begin{aligned}\mathbb{E}[(f(x) - \mu)^2] &= \sum_x \{(f(x) - \mu)^2 p(x)\} = \sum_x \{f(x)^2 p(x) - 2\mu f(x)p(x) + \mu^2 p(x)\} \\ &= \sum_x \{f(x)^2 p(x)\} - \sum_x \{2\mu f(x)p(x)\} + \sum_x \{\mu^2 p(x)\} \\ &= \sum_x \{f(x)^2 p(x)\} - 2\mu \sum_x \{f(x)p(x)\} + \mu^2 \sum_x \{p(x)\}\end{aligned}$$

그런데, $\sum_x \{p(x)\}$ 는 "random variable x 에 대한 표본공간의 모든 확률의 합은 1"이라는 확률 공리에 의해 1이 된다. 따라서, 확률 공리와 expectation의 정의에 의해 아래와 같은 식이 도출된다.

$$\begin{aligned}&= \mathbb{E}[f(x)^2] - 2\mu \mathbb{E}[f(x)] + \mu^2 && (\mathbb{E}[f(x)] \text{를 } \mu \text{라고 두었으므로}) \\ &= \mathbb{E}[f(x)^2] - 2\mu^2 + \mu^2 \\ &= \mathbb{E}[f(x)^2] - \mu^2 \\ &= \mathbb{E}[f(x)^2] - \mathbb{E}[f(x)]^2 && (\text{증명 끝})\end{aligned}$$

따라서, x 가 discrete일 때, definition 1.38으로 definition 1.39를 도출할 수 있다.

(2) x 가 continuous일 때,

x 가 continuous random variable일때, any real valued probability density function $f(x)$ 의 기대값, $\mathbb{E}[f(x)]$ 는 $\int f(x)p(x)dx$ 로 나타낼 수 있다. (이는 증명 대상이 아니므로 생략한다.) 이를 μ 라 하자. 그렇다면 definition 1.38은 아래와 같이 전개할 수 있다.

$$\begin{aligned}\mathbb{E}[(f(x) - \mu)^2] &= \int (f(x) - \mu)^2 p(x) dx = \int \{f(x)^2 - 2\mu f(x) + \mu^2\} p(x) dx \\ &= \int f(x)^2 p(x) dx - 2\mu \int f(x) p(x) dx + \mu^2 \int p(x) dx \\ &= \int f(x)^2 p(x) dx - 2\mu \int f(x) p(x) dx + \mu^2 \int p(x) dx\end{aligned}$$

그런데, $\int p(x)dx$ 는 "random variable x 에 대한 표본공간의 모든 확률의 합은 1"이라는 확률 공리에 의해 1이 된다. 따라서, 확률 공리와 expectation의 정의에 의해 아래와 같은 식이 도출된다.

$$\begin{aligned}&= \int f(x)^2 p(x) dx - 2\mu \int f(x) p(x) dx + \mu^2 \quad (\mathbb{E}[f(x)] \text{를 } \mu \text{라고 두었으므로}) \\ &= \int f(x)^2 p(x) dx - 2\mu^2 + \mu^2 \\ &= \mathbb{E}[f(x)^2] - \mu^2 \\ &= \mathbb{E}[f(x)^2] - \mathbb{E}[f(x)]^2 \quad (\text{증명 끝})\end{aligned}$$

따라서, x 가 continuous일 때, definition 1.38으로 definition 1.39를 도출할 수 있다.

(3) 결론

따라서, (1)과 (2)에 의해 x 가 continuous random variable이거나 discrete random variable일 때, $\text{var}[f] = \mathbb{E}[(f(x) - \mathbb{E}[f(x)])^2] = \mathbb{E}[f(x)^2] - \mathbb{E}[f(x)]^2$ 이 성립함을 증명할 수 있다.

1.6. Show that if two variables x and y are independent, then their covariance is zero.

Proof)

x 와 y 의 covariance는 아래 공식으로 구할 수 있다.

$$\text{covariance}[x, y] = \mathbb{E}_{x,y}[\{x - \mathbb{E}[x]\}\{y - \mathbb{E}[y]\}] = \mathbb{E}_{x,y}[xy] - \mathbb{E}[x]\mathbb{E}[y]$$

x 와 y 가 독립이므로, xy 의 기댓값은 x 와 y 각각의 기댓값의 곱, 즉 $\mathbb{E}[x]\mathbb{E}[y]$ 와 같다. 따라서, 아래와 같은 결과가 도출된다.

$$\text{covariance}[x, y] = \mathbb{E}_{x,y}[xy] - \mathbb{E}[x]\mathbb{E}[y] = \mathbb{E}[x]\mathbb{E}[y] - \mathbb{E}[x]\mathbb{E}[y] = 0$$

그러므로, x 와 y 가 서로 독립일 때, x 와 y 의 covariance는 0이다. (증명 끝)

1.9. Show that the mode (i. e. the maximum) of the Gaussian distribution (1.46) is given by μ . Similarly, show that the mode of the multivariate Gaussian (1.52) is given by μ .

Proof)

(1) **Proof for univariate Gaussian distribution (1. 46.)**

$$N(x | \mu, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} \times \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\} \quad (1. 46.)$$

Proof)

위의 Gaussian distribution의 식(1. 46.)을 미분하면 아래와 같다.

$$\begin{aligned} \frac{d}{dx}\{N(x | \mu, \sigma^2)\} &= \frac{d}{dx}\left[\frac{1}{\sigma\sqrt{2\pi}} \times \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\}\right] \\ &= \frac{1}{\sigma\sqrt{2\pi}} \times \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\} \times \left(-\frac{1}{2\sigma^2} \times 2(x - \mu)\right) \\ &= -\frac{1}{\sigma^3\sqrt{2\pi}}(x - \mu) \times \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\} \end{aligned}$$

따라서, $x = \mu$ 에서 미분 값이 0이 되고 $x > \mu, x = \mu, x < \mu$ 각각의 경우에 따라 나오는 $N(x | \mu, \sigma^2)$ 의 값에 따라 $x = \mu$ 에서 최댓값을 갖는지 증명할 수 있다. 이를 증명하면 아래와 같다.

$\exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\}$ 를 $f(x)$ 라고 하자. 표준편차 σ 와 원주율 상수 π 의 정의에 의해, $\sigma > 0, \pi > 0$ 이므로, 아래 ①, ②, ③ 경우로 나누어 판단해야 한다.

① $x > \mu$ 일 때,

$$0 < f(x) < 1$$

② $x < \mu$ 일 때,

$$0 < f(x) < 1$$

③ $x = \mu$ 일 때,

$$f(x) = 1$$

따라서, $x = \mu$ 일 때 Gaussian distribution (1. 46.)의 mode를 얻을 수 있다.

(증명끝)

(2) **Proof of multivariate Gaussian (1. 52)**

$$N(x | \mu, \Sigma) = \frac{1}{(2\pi)^{\frac{D}{2}} (|\Sigma|)^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right\} \quad (1. 52.)$$

Proof)

$$N(x | \mu, \Sigma) = \frac{1}{(2\pi)^{\frac{D}{2}} (|\Sigma|)^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right\} \text{의 양변을 미분하면 아래와 같}$$

다.

$$\begin{aligned}\frac{d}{dx}\{N(x | \mu, \Sigma)\} &= \frac{d}{dx} \left[\frac{1}{(2\pi)^{\frac{D}{2}}} \frac{1}{(|\Sigma|)^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\} \right] \\ &= \frac{1}{(2\pi)^{\frac{D}{2}}} \frac{1}{(|\Sigma|)^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\} \times \frac{d}{dx} \left[-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right]\end{aligned}$$

$f(x) = x^T A x$ 일 때, $\frac{df(x)}{dx} = (A^T + A)x$ 이므로,

$$\frac{d}{dx} \left[-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right] = -\frac{1}{2} \{ (\Sigma^{-1})^T + \Sigma^{-1} \} (x - \mu)$$

그런데, $(\Sigma^{-1})^T = \Sigma^{-1}$ 이므로,

$$-\frac{1}{2} \{ (\Sigma^{-1})^T + \Sigma^{-1} \} (x - \mu) = -\Sigma^{-1} (x - \mu)$$

$$\therefore \frac{d}{dx} \{N(x | \mu, \Sigma)\} = N(x | \mu, \Sigma) \times \{-\Sigma^{-1} (x - \mu)\}$$

따라서, $x = \mu$ 에서 미분 값이 0이 되고 최댓값을 갖기 때문에 $x = \mu$ 에서 Gaussian distribution (1. 46.)의 mode를 얻을 수 있다.

(증명 끝)

1.10. Suppose that the two variables x and z are statistically independent. Show that the mean and variance of their sum satisfies

$$\mathbb{E}[\mathbf{x} + \mathbf{z}] = \mathbb{E}[\mathbf{x}] + \mathbb{E}[\mathbf{z}] \quad (1. 128.)$$

$$\text{Var}[\mathbf{x} + \mathbf{z}] = \text{Var}[\mathbf{x}] + \text{Var}[\mathbf{z}] \quad (1. 129.)$$

Proof)

x 와 z 가 independent이므로, $p_{x,z}(xz) = p(x)p(z)$ 이다. 이 사실을 이용하여 1.128.과 1.129.를 증명하면 다음과 같다.

(1) x, z 가 discrete일 경우의 $\mathbb{E}[\mathbf{x} + \mathbf{z}] = \mathbb{E}[\mathbf{x}] + \mathbb{E}[\mathbf{z}]$ 증명

$$\begin{aligned}\mathbb{E}[\mathbf{x} + \mathbf{z}] &= \sum_x \sum_z (x + z) p_{x,z}(x, z) = \sum_x \sum_z (x + z) p(x) p(z) \\ &= \sum_x \sum_z x p(x) p(z) + \sum_x \sum_z z p(x) p(z)\end{aligned}$$

확률공리에 의해, $\sum_x \sum_z x p(x) p(z)$ 에서 $\sum_z p(z) = 1$ 이고, $\sum_x \sum_z z p(x) p(z)$ 에서 $\sum_x p(x) = 1$ 이므로

$$\begin{aligned}\sum_x \sum_z x p(x) p(z) + \sum_x \sum_z z p(x) p(z) &= \sum_x x p(x) + \sum_z z p(z) = \mathbb{E}[\mathbf{x}] + \mathbb{E}[\mathbf{z}] \\ \therefore \mathbb{E}[\mathbf{x} + \mathbf{z}] &= \mathbb{E}[\mathbf{x}] + \mathbb{E}[\mathbf{z}]\end{aligned}$$

(증명 끝)

(2) x, z 가 continuous일 경우의 $\mathbb{E}[x + z] = \mathbb{E}[x] + \mathbb{E}[z]$ 증명

$$\begin{aligned}\mathbb{E}[x + z] &= \int \int (x + z) p_{x,z}(x, z) dx dz = \int \int (x + z) p_x(x) p_z(z) dx dz \\ &= \int \int x p_x(x) p_z(z) dz dx + \int \int z p_x(x) p_z(z) dx dz \\ &= \int x p_x(x) dx + \int z p_z(z) dz = \mathbb{E}[x] + \mathbb{E}[z]\end{aligned}$$

(증명 끝)

(3) $\text{Var}[x + z] = \text{Var}[x] + \text{Var}[z]$ 의 증명

$\text{Var}[x+z]$ 는 아래와 같이 정의될 수 있다.

$$\text{Var}[x + z] = \text{Var}[x] + \text{Var}[z] + 2\text{Cov}[x, z]$$

그런데, x, z 가 independent이므로 $\text{Cov}[x, z] = 0$ 이다. 따라서, 결론은 아래와 같다.

$$\therefore \text{Var}[x + z] = \text{Var}[x] + \text{Var}[z]$$

(증명 끝)

1.11. By setting the derivatives of the log likelihood function (1.54) with respect to μ and σ^2 equal to zero, verify the results (1.55) and (1.56)

$$\ln p(\mathbf{x}|\mu, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2 - \frac{N}{2} \ln \sigma^2 - \frac{N}{2} \ln(2\pi). \quad (1.54)$$

$$\mu_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N x_n \quad (1.55)$$

$$\sigma_{\text{ML}}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{\text{ML}})^2 \quad (1.56)$$

proof of 1.55)

$$\begin{aligned}\frac{d}{d\mu} \{\ln p(x|\mu, \sigma^2)\} &= \frac{d}{d\mu} \left\{ -\frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2 - \frac{N}{2} \ln \sigma^2 - \frac{N}{2} \ln(2\pi) \right\} \\ &= -\frac{1}{2\sigma^2} \frac{d}{d\mu} \left\{ \sum_{n=1}^N (x_n - \mu)^2 \right\} = -\frac{1}{2\sigma^2} \frac{d}{d\mu} \left\{ \sum_{n=1}^N (x_n^2 - 2x_n\mu + \mu^2) \right\} \\ &= -\frac{1}{\sigma^2} \sum_{n=1}^N (\mu - x_n) = 0\end{aligned}$$

$$\sum_{n=1}^N (\mu - x_n) = 0 \quad \Rightarrow \quad N\mu + \sum_{n=1}^N -x_n = 0 \quad \Rightarrow \quad \mu = \frac{1}{N} \sum_{n=1}^N x_n$$

$$\therefore \mu_{ML} = \frac{1}{N} \sum_{n=1}^N x_n$$

(증명 끝)

proof of 1.56)

$$\begin{aligned} \frac{d}{d\sigma^2} \{\ln p(x | \mu_{ML}, \sigma^2)\} &= \frac{d}{d\sigma^2} \left\{ -\frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu_{ML})^2 - \frac{N}{2} \ln \sigma^2 - \frac{N}{2} \ln(2\pi) \right\} \\ &= -\frac{1}{2} \sum_{n=1}^N (x_n - \mu_{ML})^2 \frac{d}{d\sigma^2} \left\{ \frac{1}{\sigma^2} \right\} - \frac{N}{2} \frac{d}{d\sigma^2} \{\ln \sigma^2\} \\ &= -\frac{1}{2} \sum_{n=1}^N (x_n - \mu_{ML})^2 \left\{ -\frac{1}{\sigma^4} \right\} - \frac{N}{2\sigma^2} = 0 \end{aligned}$$

$$\frac{N}{2\sigma^2} = \frac{1}{2\sigma^4} \sum_{n=1}^N (x_n - \mu_{ML})^2 \quad \Rightarrow \quad N\sigma_{ML}^2 = \sum_{n=1}^N (x_n - \mu_{ML})^2 \quad \Rightarrow \quad \sigma_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{ML})^2$$

$$\therefore \sigma_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{ML})^2$$

(증명 끝)

1.13. Suppose that the variance of a Gaussian is estimated using the result (1.56) but with the maximum likelihood estimate μ_{ML} replaced with the true value μ of the mean. Show that this estimator has the property that its expectation is given by the true variance σ^2 .

$$\sigma_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{ML})^2 \quad (1.56)$$

Proof)

$\sigma_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{ML})^2$ 에서 μ_{ML} 을 μ 로 대체한 식은 아래와 같다.

$$\frac{1}{N} \sum_{n=1}^N (x_n - \mu)^2$$

그리고 이는 곧 σ^2 를 구하는 식과 같다. 따라서 아래의 결론을 도출할 수 있다.

$$\therefore \sigma^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu)^2$$

(증명 끝)